

Análisis Predictivo de Niveles de Ingreso y Evaluación de Equidad Algorítmica sobre el Dataset Adult Census Income

Lilit Ameli Gutierrez Pancorbo¹ and Teresa Chipa Cardenas¹

Universidad Nacional Micaela Bastidas de Apurímac, Facultad de Ingeniería,
Tamburco, Perú

Resumen La clasificación de ingresos en *Adult Census Income* presenta un desbalance entre las clases $\leq 50K$ y $> 50K$, lo que puede ocultar un desempeño insuficiente sobre la clase minoritaria cuando se utiliza únicamente la exactitud. Se compararon regresión logística, árbol de decisión, Random Forest y Support Vector Machine mediante tres experimentos: (1) línea base sin balanceo ni búsqueda de hiperparámetros; (2) aplicación de SMOTE, ADASYN y RandomOverSampler; y (3) selección de SMOTE e integración con GridSearchCV. La evaluación incluyó accuracy, precision, recall, F1-score, ROC-AUC, Matthews Correlation Coefficient y balanced accuracy. Después de imputar valores faltantes y eliminar 24 duplicados, se trabajó con 32,537 registros y 82 predictores. Random Forest obtuvo el mayor F1 de la línea base (0.6643); con SMOTE aumentó a 0.6776; y con SMOTE más GridSearchCV alcanzó $F1=0.6916$, $recall=0.7793$, $ROC-AUC=0.9063$ y $MCC=0.5856$. El balanceo mejoró la detección de la clase positiva, aunque redujo accuracy y precision. Los notebooks no calculan métricas de equidad por sexo, raza o edad; por ello, el artículo distingue los resultados predictivos realmente implementados de la auditoría de equidad recomendada como extensión.

Keywords: Adult Census Income · clasificación desbalanceada · SMOTE · ADASYN · Random Forest · GridSearchCV · equidad algorítmica.

1. Introducción

El aprendizaje automático permite modelar relaciones entre características demográficas, educativas y laborales y una categoría económica de interés. En *Adult Census Income*, la tarea consiste en predecir si el ingreso anual de una persona supera los 50,000 dólares. El conjunto fue difundido por Kohavi y Becker y se convirtió en un referente para comparar clasificadores y estudiar sesgo algorítmico [21,20,29]. Su uso extendido favorece la reproducibilidad, pero no elimina las limitaciones derivadas de su origen censal de 1994 y de un umbral económico que no representa las condiciones actuales [12].

Una dificultad central es el desbalance de la variable objetivo: aproximadamente tres cuartas partes de los casos pertenecen a $\leq 50K$ y solo una cuarta parte a $> 50K$. Un clasificador puede obtener una accuracy alta favoreciendo la clase

mayoritaria y, al mismo tiempo, omitir numerosos positivos. Por ello, la literatura recomienda complementar accuracy con precision, recall, F1, ROC-AUC, MCC y balanced accuracy [28,10,6]. Las técnicas de sobremuestreo intentan corregir este problema. RandomOverSampler replica casos existentes, SMOTE interpola observaciones minoritarias y ADASYN concentra la generación sintética en zonas difíciles [8,18,23].

Diversos trabajos han aplicado árboles, Random Forest, modelos probabilísticos y boosting a la clasificación de ingresos [5,7,2,15,9]. No obstante, el presente estudio limita sus resultados a los cuatro algoritmos ejecutados en los notebooks: regresión logística, árbol de decisión, Random Forest y SVM. Esta precisión corrige el manuscrito inicial, que mencionaba Gradient Boosting, XGBoost y Naive Bayes sin evidencia experimental correspondiente.

El dataset incluye atributos sensibles como **sex**, **race** y **age**. Un rendimiento agregado favorable no demuestra trato equitativo, porque pueden existir diferencias de selección, verdaderos positivos o falsos positivos entre grupos. La equidad requiere métricas y criterios explícitos, como paridad demográfica, igualdad de oportunidades o *equalized odds* [13,17,3,25]. También existen estrategias de reponderación, restricciones y optimización multiobjetivo [19,1,26]; sin embargo, estas no fueron implementadas en los notebooks y se presentan únicamente como recomendaciones.

El objetivo general es comparar los cuatro clasificadores bajo tres configuraciones: sin balanceo, con tres técnicas de sobremuestreo y con la mejor técnica seguida de GridSearchCV. Se busca determinar el mejor modelo considerando simultáneamente Accuracy, Precision, Recall, F1-score y ROC-AUC, complementados con MCC y balanced accuracy; explicar el efecto del balanceo y de la optimización; y establecer qué afirmaciones sobre equidad están realmente respaldadas. La contribución es una comparación trazable de los tres experimentos, con una separación clara entre resultados implementados y mejoras futuras.

2. Método

2.1. Dataset

El dataset Adult Census Income fue compilado por Barry Becker a partir de los datos del censo de Estados Unidos de 1994, específicamente de la Current Population Survey (CPS) realizada por la U.S. Census Bureau [12]. Posteriormente, fue donado al UCI Machine Learning Repository y desde entonces se ha convertido en un recurso ampliamente utilizado en la comunidad de minería de datos y aprendizaje automático [21]. El conjunto de datos es accesible a través de OpenML con el identificador 1590 [29].

El dataset contiene 48,842 instancias y 14 atributos que describen características demográficas y socioeconómicas de individuos. La variable objetivo es binaria: si el ingreso anual es mayor a 50,000 USD o menor o igual a este umbral.

Los atributos del dataset se dividen en categóricos y continuos. En las Tablas 1 y 2 se resumen respectivamente.

Cuadro 1. Descripción de variables numéricas del dataset Adult Census Income.

Atributo	Tipo	Rango	Descripción
age	Continuo	17 – 90 años	Edad del individuo
fnlwgt	Continuo	12,285 – 1,484,705	Peso final (factor de ponderación censal)
education.num	Continuo	1 – 16 años	Años de educación formal
capital.gain	Continuo	0 – 99,999 USD	Ganancia de capital
capital.loss	Continuo	0 – 4,356 USD	Pérdida de capital
hours.per.week	Continuo	1 – 99 horas	Horas trabajadas por semana

Cuadro 2. Descripción de variables categóricas del dataset Adult Census Income.

Atributo	Tipo	Categorías	Descripción
workclass	Catagórico	8	Sector laboral (ej. Private, Self-emp-not-inc, Local-gov)
education	Catagórico	16	Nivel educativo (ej. HS-grad, Bachelors, Masters)
marital.status	Catagórico	7	Estado civil (ej. Married, Never-married, Divorced)
occupation	Catagórico	14	Ocupación específica (ej. Prof-specialty, Craft-repair)
relationship	Catagórico	6	Rol dentro del núcleo familiar (ej. Husband, Wife, Own-child)
race	Catagórico	5	Raza auto-reportada (ej. White, Black, Asian-Pac-Islander)
sex	Catagórico	2	Género (Male, Female)
native.country	Catagórico	41	País de nacimiento (ej. United-States, Mexico, Philippines)
income	Catagórico (Target)	2	Nivel de ingreso (<=50K o >50K)

Esta distribución evidencia un desbalance significativo entre las clases.

2.2. Análisis Exploratorio de Datos (EDA)

El EDA identificó valores faltantes codificados con “?” en tres variables: 1,836 en `workclass`, 1,843 en `occupation` y 583 en `native.country`. La distribución objetivo antes de eliminar duplicados fue 24,720 observaciones $\leq 50K$ y 7,841 $> 50K$. La Figura 1 resume ambos hallazgos. El desbalance explica por qué una predicción constante de la clase mayoritaria ya alcanzaría cerca de 0.76 de accuracy, pero recall igual a cero para la clase positiva.




Figura 1. Valores faltantes y distribución de la variable objetivo.

La matriz de correlación de Pearson muestra relaciones lineales generalmente bajas. La asociación más alta entre predictores numéricos se observa entre `education.num` y `hours.per.week` (aproximadamente 0.15), seguida por `education.num` y `capital.gain` (0.12). Esto sugiere que los modelos deben capturar relaciones no lineales e interacciones, pero no permite inferir causalidad. Las variables de capital presentan fuertes asimetrías, con gran concentración en cero.




Figura 2. Matriz de correlación de las variables numéricas.

Mediante el rango intercuartílico se detectaron 143 atípicos en `age`, 992 en `fnlwgt`, 1,198 en `education.num`, 2,712 en `capital.gain`, 1,519 en `capital.loss` y 9,008 en `hours.per.week`. No se eliminaron automáticamente porque valores extremos como jornadas laborales inusuales o ganancias de capital elevadas pueden ser observaciones válidas y predictivamente informativas.

La composición demográfica tampoco es uniforme: 66.92% corresponde a **Male** y 33.08% a **Female**; la categoría **White** reúne 85.43% de los registros. Estas diferencias no prueban discriminación, pero advierten que las métricas globales estarán dominadas por grupos frecuentes. Estudios sobre *Adult Census Income* han cuestionado precisamente su representatividad y validez externa para investigaciones de equidad contemporánea [12,16,22].

2.3. Preprocesamiento de Datos

La lectura utilizó `na_values='?'` para reconocer ausencias. Los valores faltantes categóricos fueron imputados con la moda de cada columna y se eliminaron 24 duplicados. La variable `education` se excluyó por redundancia con

`education.num`. Después, `income` se transformó a 0/1 y las variables categóricas se codificaron mediante one-hot encoding con `drop_first=True`, obteniéndose 82 predictores.

La implementación aplicó `StandardScaler` al conjunto completo de predictores antes de la partición. Luego se realizó una división estratificada 80/20 con `test_size=0.20` y `random_state=42`. Esta descripción coincide con los notebooks, pero revela una amenaza de fuga de información: el escalador conoce la media y desviación del futuro conjunto de prueba. Los resultados se conservan para mantener trazabilidad, aunque una réplica de publicación debe ajustar imputación, codificación y escalado solo con entrenamiento mediante un pipeline [27].

En el Experimento 2, SMOTE, ADASYN y RandomOverSampler se aplicaron únicamente al entrenamiento. SMOTE y RandomOverSampler produjeron 39,516 muestras equilibradas (19,758 por clase), mientras ADASYN generó 39,817 (19,758 negativas y 20,059 positivas). El conjunto de prueba permaneció sin alteraciones. En el Experimento 3 se empleó un pipeline de *imbalanced-learn* para ejecutar SMOTE dentro de cada fold de GridSearchCV, evitando que las muestras sintéticas de validación influyeran en el entrenamiento [23].

2.4. Algoritmos de Machine Learning

La regresión logística modela la probabilidad positiva mediante $P(y = 1|x) = 1/(1 + e^{-(\beta_0 + \beta^T x)})$. En la línea base se utilizó `max_iter=5000`, $C = 1$ y penalización L_2 . El árbol de decisión empleó impureza de Gini, profundidad máxima 10 y semilla 42. Random Forest combinó 200 árboles y paralelización con `n_jobs=-1`; su capacidad para promediar árboles reduce varianza y captura interacciones no lineales [5]. SVM utilizó kernel RBF, $C = 1$ y $\gamma = \text{scale}$, siguiendo el principio de máximo margen [11].

Cuadro 3. Diseño de los tres experimentos.

Experimento	Tratamiento	Propósito
1	Distribución original; hiperparámetros base.	Establecer la línea base comparable.
2	SMOTE, ADASYN y RandomOverSampler sobre entrenamiento.	Medir el efecto aislado del balanceo.
3	SMOTE dentro de pipeline y GridSearchCV de 3 folds.	Medir el efecto adicional de la optimización.

GridSearchCV evaluó 30 configuraciones con `StratifiedKFold(n_splits=3, shuffle=True, random_state=42)` y F1 como criterio. Se probaron 6 combinaciones para regresión logística, 12 para árbol, 8 para Random Forest y 4 para SVM, equivalentes a 90 ajustes internos. El espacio incluyó C y penalización

para regresión; profundidad, división y hoja para el árbol; número de árboles, profundidad y tamaño de hoja para Random Forest; y kernels lineal/RBF con diferentes valores de C para SVM.

2.5. Métricas de Evaluación

A partir de verdaderos positivos (TP), verdaderos negativos (TN), falsos positivos (FP) y falsos negativos (FN), se calcularon:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}, \quad Precision = \frac{TP}{TP + FP}, \quad (1)$$

$$Recall = \frac{TP}{TP + FN}, \quad F1 = 2 \frac{Precision \cdot Recall}{Precision + Recall}. \quad (2)$$

Accuracy resume aciertos globales; precision mide la confiabilidad de las predicciones $>50K$; recall mide la capacidad para recuperar positivos; y F1 equilibra precision y recall. ROC-AUC evalúa la discriminación a través de umbrales [14]. MCC incorpora los cuatro componentes de la matriz y es robusto ante desbalance [24,10]. Balanced accuracy promedia la sensibilidad de ambas clases [6]. Se priorizó F1 para la selección, pero el ganador debía mostrar consistencia en ROC-AUC, MCC y balanced accuracy. Los notebooks no realizaron pruebas inferenciales repetidas; por ello, las diferencias se interpretan descriptivamente y no como significancia estadística.

3. Resultados

Experimento 1. Random Forest obtuvo la mejor accuracy (0.8519), F1 (0.6643), ROC-AUC (0.8992) y MCC (0.5743). El árbol logró el mayor recall (0.6212), mientras SVM presentó la precision más alta (0.7353), pero el recall más bajo (0.5491). La validación cruzada de cinco folds registrada en el notebook mantuvo a Random Forest en primer lugar, con F1 medio de 0.6840 ± 0.0057 .

Cuadro 4. Resultados del Experimento 1 sin balanceo.

Modelo	Acc.	Prec.	Recall	F1	AUC	MCC	BAcc.
Regresión logística	.8508	.7345	.5963	.6582	.8986	.5691	.7639
Árbol de decisión	.8485	.7130	.6212	.6639	.8855	.5690	.7709
Random Forest	.8519	.7316	.6084	.6643	.8992	.5743	.7688
SVM	.8437	.7353	.5491	.6287	.8893	.5415	.7432

Las matrices de confusión muestran el costo del desbalance. Random Forest produjo 4,590 verdaderos negativos, 350 falsos positivos, 614 falsos negativos y 954 verdaderos positivos. SVM fue más conservador: redujo los falsos positivos a 310, pero elevó los falsos negativos a 707. En consecuencia, su precision fue alta y su F1 bajo.




Figura 3. Comparación de F1 y MCC en el Experimento 1.

Experimento 2. El sobremuestreo incrementó el recall en los cuatro modelos, pero redujo con frecuencia accuracy y precision. La mejor combinación según F1 fue Random Forest con SMOTE (0.6776), seguida por Random Forest con RandomOverSampler (0.6769) y regresión logística con RandomOverSampler (0.6753). ADASYN produjo los recalls más altos, especialmente en SVM (0.8782), aunque con precision 0.5048 y MCC 0.5241. Esto indica una frontera muy inclinada hacia la clase positiva.

Cuadro 5. Resultados completos del Experimento 2.

Técnica	Modelo	Acc.	Prec.	Recall	F1	MCC	BAcc.
SMOTE	Logística	.8062	.5677	.8214	.6714	.5589	.8114
SMOTE	Árbol	.8065	.5716	.7864	.6620	.5445	.7997
SMOTE	Random Forest	.8405	.6604	.6958	.6776	.5721	.7911
SMOTE	SVM	.8050	.5667	.8106	.6670	.5523	.8069
ADASYN	Logística	.7815	.5282	.8731	.6582	.5464	.8128
ADASYN	Árbol	.7863	.5365	.8291	.6515	.5323	.8009
ADASYN	Random Forest	.8278	.6278	.7003	.6620	.5484	.7842
ADASYN	SVM	.7631	.5048	.8782	.6411	.5241	.8024
ROS	Logística	.8065	.5669	.8348	.6753	.5652	.8162
ROS	Árbol	.8035	.5620	.8355	.6720	.5608	.8144
ROS	Random Forest	.8442	.6764	.6773	.6769	.5742	.7872
ROS	SVM	.7982	.5551	.8189	.6617	.5455	.8053

SMOTE fue seleccionado para el Experimento 3 porque obtuvo el mayor F1 global y mejoró de forma consistente los cuatro modelos. En Random Forest aumentó el recall de 0.6084 a 0.6958 y el F1 de 0.6643 a 0.6776. En SVM generó la mayor ganancia de F1 del segundo experimento (+0.0383). RandomOverSampler fue competitivo y alcanzó el mayor MCC, pero la selección siguió el criterio F1 establecido.




Figura 4. Accuracy, recall y F1 para los modelos y balanceadores del Experimento 2.

Experimento 3. Random Forest optimizado alcanzó el mejor rendimiento conjunto: F1=0.6916, ROC-AUC=0.9063, MCC=0.5856 y balanced accuracy=0.8144. Regresión logística obtuvo el mayor recall (0.8214), pero precisión 0.5677. SVM logró recall 0.8208 y F1 0.6735, con el mayor tiempo de búsqueda (785.92 s). GridSearchCV produjo una mejora relevante en Random Forest, moderada en SVM y marginal o nula en los otros modelos.

Cuadro 6. Resultados y mejores hiperparámetros del Experimento 3.

Modelo	Mejores hiperparámetros	Acc.	Prec.	Recall	F1	AUC	MCC
Logística	$C = 1$, $\text{penalty}=L_2$	.8062	.5677	.8214	.6714	.8986	.5589
Árbol	$\text{depth}=10$, $\text{leaf}=1$, $\text{split}=10$	.8065	.5714	.7883	.6626	.8802	.5453
Random Forest	$\text{depth}=\text{None}$, $\text{leaf}=3$, $\text{features}=\text{sqrt}$, $n = 200$	.8325	.6216	.7793	.6916	.9063	.5856
SVM	$C = 2$, $\text{gamma}=\text{scale}$, RBF	.8082	.5710	.8208	.6735	.8913	.5618

La matriz de Random Forest optimizado contiene 4,196 verdaderos negativos, 744 falsos positivos, 346 falsos negativos y 1,222 verdaderos positivos. Frente a la línea base, los falsos negativos disminuyeron en 268 casos (43.65 %), mientras los falsos positivos aumentaron en 394. Esta compensación explica el aumento de recall y la reducción de accuracy y precisión.




Figura 5. Matriz de confusión y curva ROC de Random Forest optimizado.

La comparación integrada confirma que Random Forest es el modelo ganador. Su F1 aumenta de 0.6643 en la línea base a 0.6776 con SMOTE y a 0.6916 con GridSearchCV. El recall crece de 0.6084 a 0.7793 y la AUC de 0.8992 a 0.9063. Aunque SVM presenta la mayor mejora total de F1, su resultado final continúa por debajo de Random Forest.




Figura 6. F1-score de los cuatro modelos a través de los tres experimentos.

4. Discusiones

Los resultados muestran que balancear la clase objetivo modifica el costo efectivo de los errores. Con la distribución original, existen aproximadamente tres negativos por cada positivo y la función de aprendizaje favorece la accuracy global. Al equilibrar el entrenamiento, los errores positivos adquieren mayor peso y los modelos predicen más casos >50K. Por ello, el aumento de recall y la reducción de precision son efectos esperables, no una anomalía. SMOTE fue especialmente útil para Random Forest, posiblemente porque la interpolación enriqueció regiones minoritarias y el ensemble pudo capturar interacciones sin depender de una sola frontera. ADASYN obtuvo sensibilidad alta, pero también pareció amplificar regiones ambiguas, evidenciado por su menor precision y MCC.

La caída de accuracy no significa automáticamente un modelo peor. Random Forest optimizado disminuyó de 0.8519 a 0.8325 en accuracy, pero elevó recall de 0.6084 a 0.7793 y F1 de 0.6643 a 0.6916. En un contexto donde omitir positivos resulte costoso, este compromiso puede ser preferible. Si el objetivo fuera maximizar aciertos totales con costos simétricos, la línea base sería competitiva. La decisión debe vincularse al uso previsto y a una matriz de costos explícita.

GridSearchCV no mejoró uniformemente todos los modelos. En Random Forest, el mínimo de tres muestras por hoja regularizó regiones pequeñas y la profundidad libre conservó flexibilidad, generando aumentos de F1, AUC y MCC. En regresión logística, la mejor configuración coincidió con la base; en el árbol la mejora fue casi nula; y SVM requirió mucho más tiempo sin superar al ensemble. El resultado debe interpretarse como el mejor dentro de una rejilla reducida, no como óptimo global. No se exploraron pesos de clase, parámetros del balanceador, calibración ni umbrales.

Los niveles de accuracy cercanos a 0.85 son comparables con antecedentes sobre *Adult Census Income* [7,2]. Sin embargo, las comparaciones entre estudios deben considerar versión del dataset, limpieza, partición y métrica. El aporte principal aquí es mostrar, sobre el mismo test, cómo cambia la detección de la clase minoritaria. La divergencia entre F1, MCC y recall también respalda la recomendación de no resumir el rendimiento con una sola métrica [28,10].

Respecto de la equidad algorítmica, los notebooks no reportan tasas de selección, TPR, FPR, precision o calibración por sexo, raza o edad. Tampoco implementan reponderación, restricciones ni optimización multiobjetivo. Por ello, no puede concluirse que el modelo ganador sea equitativo ni que SMOTE reduzca disparidades demográficas. Balancear `income` y mitigar sesgo de grupo son problemas diferentes. Una auditoría futura debe calcular diferencia y razón de paridad demográfica, igualdad de oportunidades y equalized odds sobre el test original, acompañadas de tamaños de grupo e intervalos de confianza [17,3,4]. Si se detectan disparidades, pueden compararse reponderación [19], reducciones con restricciones [1] u optimización Pareto [26].

La revisión detectó inconsistencias que fueron corregidas: el manuscrito inicial reportaba 48,842 instancias aunque el notebook usa 32,561; describía algoritmos no ejecutados; presentaba resultados como esperados; y afirmaba una evaluación de equidad sin métricas por grupo. También debe reconocerse una limitación del

código: el escalado se ajustó antes del train-test split. Además, SMOTE aplicado sobre one-hot encoding estandarizado puede producir valores continuos en variables originalmente binarias; SMOTENC sería más apropiado. Otras mejoras recomendadas son pipeline completo desde la imputación, validación cruzada repetida o bootstrap pareado, intervalos de confianza, calibración, optimización del umbral, búsqueda aleatoria o bayesiana e interpretación mediante importancia por permutación o SHAP. Finalmente, la antigüedad del dataset limita la validez externa y justifica validar con datos contemporáneos como Folktables [12].

5. Conclusiones

La evaluación demuestra que una accuracy cercana al 85% no basta para caracterizar la predicción de la clase minoritaria en *Adult Census Income*. En el Experimento 1, Random Forest fue la mejor línea base con $F1=0.6643$, $ROC-AUC=0.8992$ y $MCC=0.5743$, pero $recall=0.6084$ para ingresos $>50K$.

En el Experimento 2, el sobremuestreo incrementó el recall en todos los algoritmos y redujo generalmente precision y accuracy. Random Forest con SMOTE obtuvo el mayor $F1$ (0.6776), mientras RandomOverSampler produjo un resultado muy cercano y el mayor MCC. ADASYN consiguió recalls elevados a costa de numerosos falsos positivos. El balanceo, por tanto, mejora la sensibilidad, pero no todas las métricas ni todos los modelos de igual manera.

En el Experimento 3, Random Forest con SMOTE y GridSearchCV alcanzó el mejor desempeño conjunto: $accuracy=0.8325$, $precision=0.6216$, $recall=0.7793$, $F1=0.6916$, $ROC-AUC=0.9063$, $MCC=0.5856$ y $balanced\ accuracy=0.8144$. Respecto de la línea base, $F1$ aumentó 0.0273 y recall 0.1709, reduciendo 268 falsos negativos. Por liderar $F1$, AUC, MCC y balanced accuracy, se selecciona como mejor modelo.

GridSearchCV aportó una mejora clara solo en Random Forest y no constituye una garantía automática. Finalmente, la evidencia disponible no demuestra equidad algorítmica: el análisis por grupos no fue implementado. La extensión prioritaria consiste en corregir la fuga de preprocesamiento, aplicar SMOTENC, incorporar validación repetida e intervalos de confianza, optimizar el umbral y ejecutar una auditoría formal de paridad demográfica, igualdad de oportunidades y equalized odds.

Referencias

1. Agarwal, A., Beygelzimer, A., Dudik, M., Langford, J., Wallach, H.: A reductions approach to fair classification. *Proceedings of the 35th International Conference on Machine Learning* **80**, 60–69 (2018)
2. Amanda, W., Voutama, A.: Income classification using random forest algorithm: Case study adult income dataset. *Journal of Computer Science and Technology* **14**(1) (2025)
3. Barocas, S., Hardt, M., Narayanan, A.: *Fairness and Machine Learning: Limitations and Opportunities*. fairmlbook.org (2019)

4. Bendoukha, A.A., Kaaniche, N., Boudguiga, A., Sirdey, R.: FairCognizer: A model for accurate predictions with inherent fairness evaluation. In: ECAI 2024: 27th European Conference on Artificial Intelligence. Frontiers in Artificial Intelligence and Applications, IOS Press (2024)
5. Breiman, L.: Random forests. *Machine Learning* **45**(1), 5–32 (2001)
6. Brodersen, K.H., Ong, C.S., Stephan, K.E., Buhmann, J.M.: The balanced accuracy and its posterior distribution. In: Proceedings of the 20th International Conference on Pattern Recognition. pp. 3121–3124 (2010)
7. Chakrabarty, N., Biswas, S.: A statistical approach to adult census income level prediction. In: Proceedings of the International Conference on Advances in Computing, Communication Control and Networking. pp. 207–212 (2018)
8. Chawla, N.V., Bowyer, K.W., Hall, L.O., Kegelmeyer, W.P.: SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research* **16**, 321–357 (2002)
9. Chen, T., Guestrin, C.: XGBoost: A scalable tree boosting system. In: Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. pp. 785–794 (2016)
10. Chicco, D., Jurman, G.: The advantages of the matthews correlation coefficient over f1 score and accuracy in binary classification evaluation. *BMC Genomics* **21**(6), 1–13 (2020)
11. Cortes, C., Vapnik, V.: Support-vector networks. *Machine Learning* **20**(3), 273–297 (1995)
12. Ding, F., Hardt, M., Miller, J., Schmidt, L.: Retiring adult: New datasets for fair machine learning. In: Advances in Neural Information Processing Systems. vol. 34, pp. 6478–6490 (2021)
13. Dwork, C., Hardt, M., Pitassi, T., Reingold, O., Zemel, R.: Fairness through awareness. In: Proceedings of the 3rd Innovations in Theoretical Computer Science Conference. pp. 214–226 (2012)
14. Fawcett, T.: An introduction to ROC analysis. *Pattern Recognition Letters* **27**(8), 861–874 (2006)
15. Friedman, J.H.: Greedy function approximation: A gradient boosting machine. *The Annals of Statistics* **29**(5), 1189–1232 (2001)
16. Girhepuje, S.: Identifying and Examining Machine Learning Biases on Adult Dataset. M.tech. thesis, Indian Institute of Technology Madras (2021)
17. Hardt, M., Price, E., Srebro, N.: Equality of opportunity in supervised learning. In: Advances in Neural Information Processing Systems. vol. 29, pp. 3315–3323 (2016)
18. He, H., Bai, Y., Garcia, E.A., Li, S.: ADASYN: Adaptive synthetic sampling approach for imbalanced learning. In: Proceedings of the IEEE International Joint Conference on Neural Networks. pp. 1322–1328 (2008)
19. Kamiran, F., Calders, T.: Data preprocessing techniques for classification without discrimination. *Knowledge and Information Systems* **33**(1), 1–33 (2012)
20. Kohavi, R.: Scaling up the accuracy of naive-bayes classifiers: A decision-tree hybrid. In: Proceedings of the Second International Conference on Knowledge Discovery and Data Mining. pp. 202–207. AAAI Press (1996)
21. Kohavi, R., Becker, B.: Adult data set. UCI Machine Learning Repository (1996), dataset derived from the 1994 United States Census database
22. Kokate, A., Nemade, B., Badhe, N., Mali, D., Gaikwad, K., Ansari, N.: Bias and its consequences: A study of machine learning models on biased data. *International Journal of Scientific Research in Computer Science, Engineering and Information Technology* **10**(6), 290–301 (2024)

23. Lemaître, G., Nogueira, F., Aridas, C.K.: Imbalanced-learn: A python toolbox to tackle the curse of imbalanced datasets in machine learning. *Journal of Machine Learning Research* **18**(17), 1–5 (2017)
24. Matthews, B.W.: Comparison of the predicted and observed secondary structure of T4 phage lysozyme. *Biochimica et Biophysica Acta* **405**(2), 442–451 (1975)
25. Mehrabi, N., Morstatter, F., Saxena, N., Lerman, K., Galstyan, A.: A survey on bias and fairness in machine learning. *ACM Computing Surveys* **54**(6), 1–35 (2021)
26. Nagpal, R., Shahsavarifar, R.R., Goyal, V., Gupta, A.: Optimizing fairness and accuracy: A pareto optimal approach for decision-making. *AI and Ethics* **5**, 1743–1756 (2025). <https://doi.org/10.1007/s43681-024-00508-4>
27. Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., et al.: Scikit-learn: Machine learning in python. *Journal of Machine Learning Research* **12**, 2825–2830 (2011)
28. Saito, T., Rehmsmeier, M.: The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLOS ONE* **10**(3), e0118432 (2015)
29. Vanschoren, J., van Rijn, J.N., Bischl, B., Torgo, L.: OpenML: Networked science in machine learning. *ACM SIGKDD Explorations Newsletter* **15**(2), 49–60 (2014)