

Análisis Predictivo de Niveles de Ingreso y Evaluación de Equidad Algorítmica sobre el Dataset “Adult Census Income”

Lilit Ameli Gutierrez Pancorbo¹ and Teresa Chipa Cardenas²

Universidad Micaela Bastidas de Apurímac, Facultad de Ingeniería, Tamburco, Perú

Abstract. This report presents a comprehensive technical analysis of the Adult Census Income dataset, which is widely used in machine learning for binary income classification. It examines both the predictive performance of various models—particularly those based on Gradient Boosting and XGBoost—and the ethical implications arising from historical biases present in the data. Consequently, a methodological framework is proposed that integrates algorithmic fairness metrics, such as statistical parity and equality of opportunity, alongside mitigation techniques like re-weighting and multi-objective optimization. Expected results indicate high accuracy levels—exceeding 85%—albeit at the cost of potential disparities that can be significantly reduced through fairness-aware interventions. Finally, the report concludes with recommendations for adopting hybrid models and conducting continuous audits, thereby contributing to the development of more responsible, transparent, and equitable AI systems.

Keywords: Adult Census Income · Machine Learning · Algorithmic Fairness · Gradient Boosting · XGBoost · Income Classification.

1 Introducción

La desigualdad de ingresos constituye uno de los desafíos socioeconómicos más urgentes de las sociedades contemporáneas, particularmente en Estados Unidos, donde la brecha económica entre distintos niveles poblacionales ha generado un creciente interés por parte de gobiernos, instituciones académicas y organismos internacionales [17]. En este contexto, el aprendizaje automático y la minería de datos han emergido como herramientas fundamentales para comprender los patrones subyacentes que determinan el nivel de ingresos de los individuos, permitiendo no solo la predicción precisa de esta variable, sino también la identificación de factores críticos que inciden en la movilidad económica [18]. El dataset Adult Census Income, derivado del censo de EE.UU. de 1994 y alojado en el repositorio UCI, se ha consolidado como un estándar de referencia en la comunidad de aprendizaje automático, siendo citado en más de trescientas investigaciones relacionadas con equidad algorítmica y clasificación binaria [19]. Este conjunto de datos, que contiene 48,842 instancias y 14 atributos demográficos y socioeconómicos, plantea el desafío de predecir si el ingreso anual de un

individuo supera los 50,000 USD, constituyendo un escenario ideal para evaluar modelos de clasificación y, simultáneamente, analizar las implicaciones éticas de las decisiones automatizadas en contextos sensibles [20]. El Adult Income Dataset, derivado del censo de EE. UU. de 1994, se ha consolidado como un estándar icónico en el dominio del aprendizaje automático para evaluar modelos de clasificación binaria que predicen si el ingreso anual de un individuo supera los 50,000 USD [12]. Este dataset ha aparecido en cientos de artículos de investigación, sirviendo como base para el desarrollo y comparación de numerosas intervenciones de equidad algorítmica [8].

La problemática fundamental que aborda esta investigación radica en la presencia de prejuicios históricos y representativos en los datos de entrenamiento, los cuales pueden conducir a resultados discriminatorios que perpetúan la desigualdad socioeconómica [21]. El dataset Adult Census Income presenta un desbalance significativo en la representación de grupos demográficos, con una sobrerrepresentación de hombres blancos y una infrarrepresentación de mujeres y minorías étnicas, lo que afecta la capacidad de los modelos para generalizar equitativamente [22]. Además, el umbral de ingresos de 50,000 USD, que en 1994 correspondía al percentil 76 de la distribución de ingresos en EE.UU. y a los percentiles 88 y 89 para las poblaciones afroamericana y femenina respectivamente, resulta idiosincrásico y puede no reflejar fielmente la realidad económica actual [19]. Esta tensión intrínseca entre maximizar la precisión predictiva y garantizar la equidad algorítmica constituye el núcleo del problema de investigación, especialmente relevante en dominios críticos como la aprobación de préstamos, la contratación laboral y la justicia penal, donde las decisiones automatizadas tienen consecuencias tangibles en la vida de las personas [20].

Diversas investigaciones evidencian múltiples enfoques para abordar la clasificación de ingresos y la equidad algorítmica en este dataset. Kohavi [18] propuso el algoritmo híbrido NBTree, que combina árboles de decisión con clasificadores Naive-Bayes, logrando mejoras significativas en la precisión para conjuntos de datos de gran escala. Chakrabarty y Biswas [17] demostraron que el Gradient Boosting Classifier, con un ajuste exhaustivo de hiperparámetros mediante búsqueda en rejilla, alcanza una precisión del 88.16%, estableciendo un punto de referencia en el estado del arte. En el ámbito de la equidad algorítmica, Bendoukha et al. [23] introdujeron FairCognizer, un marco de aprendizaje con doble etiquetado que permite evaluar el riesgo de injusticia por predicción, manteniendo la precisión óptima (86% en Adult) mientras proporciona información sobre la vulnerabilidad de registros individuales a la injusticia grupal. Nagpal et al. [20] exploraron la aplicación del optimizador Minimax Pareto para equilibrar la precisión con la equidad individual y grupal, encontrando que es posible reducir la disparidad de paridad estadística (del 0.22 al 0.003) con una disminución mínima en la precisión (menos del 0.6%). Por su parte, Ding et al. [19] cuestionaron la validez externa del dataset Adult debido a su antigüedad y propusieron el conjunto de datos Folktables, derivado de la Encuesta Comunitaria Americana, como un reemplazo moderno que permite estudiar variaciones geográficas y temporales. Aninze y Bhogal [21] investigaron la efectividad de téc-

nicas de mitigación como el re-pesaje mediante Gradient Boosting exponencial, logrando reducir la disparidad de paridad estadística del 22% al 3%, aunque con una disminución de la precisión del 87% al 85% y un incremento en la tasa de falsos negativos para el grupo masculino.

El objetivo general de esta investigación es desarrollar y comparar modelos de aprendizaje automático para la clasificación de ingresos, integrando métricas de evaluación de justicia algorítmica para mitigar sesgos en el dataset *Adult Census Income*. Los objetivos específicos incluyen: (1) analizar el impacto de los atributos protegidos (sexo, raza, edad) en las predicciones del modelo mediante funciones de alternancia y divergencia de Kullback-Leibler, siguiendo la metodología propuesta por Girhepuje [22]; (2) implementar y evaluar el rendimiento de algoritmos de *ensemble learning*, específicamente *Gradient Boosting* y *XGBoost*, como punto de referencia de precisión; (3) explorar técnicas de mitigación de sesgos, como el re-pesaje de muestras [21] y la optimización multiobjetivo [20]; y (4) evaluar la efectividad de los modelos híbridos que combinan árboles de decisión con clasificadores Naive-Bayes [18]. Con estos objetivos, se pretende contribuir al desarrollo de sistemas de aprendizaje automático responsables y transparentes, aplicables a procesos de toma de decisiones críticas en dominios socioeconómicos.

El presente artículo se organiza de la siguiente manera. La Sección 2 describe la metodología empleada, incluyendo la descripción detallada del dataset Adult Census Income, el análisis exploratorio de datos (EDA), las técnicas de pre-procesamiento aplicadas, los algoritmos de aprendizaje automático implementados (Gradient Boosting, XGBoost, Random Forest, Naive-Bayes) y las métricas de evaluación utilizadas tanto para rendimiento predictivo (precisión, recall, F1-score, AUC-ROC) como para equidad algorítmica (paridad estadística, igualdad de oportunidades). La Sección 3 presenta los resultados obtenidos mediante los experimentos y la evaluación comparativa de los modelos, incluyendo el análisis de sesgos mediante funciones de alternancia y divergencia KL. La Sección 4 discute los hallazgos, interpretando los resultados a la luz de los antecedentes científicos y destacando las limitaciones del estudio, particularmente en relación con la validez externa del dataset y las compensaciones entre precisión y equidad. Finalmente, la Sección 5 concluye el trabajo resumiendo las contribuciones principales, extrayendo implicaciones para el desarrollo de sistemas de IA justos y proponiendo líneas de investigación futuras, como la aplicación de modelos híbridos de deep learning y la validación con datasets contemporáneos como Folktables.

2 Método

2.1 Dataset

El dataset Adult Census Income fue compilado por Barry Becker a partir de los datos del censo de Estados Unidos de 1994, específicamente de la Current Population Survey (CPS) realizada por la U.S. Census Bureau [8]. Posteriormente, fue donado al UCI Machine Learning Repository y desde entonces se ha

convertido en un recurso ampliamente utilizado en la comunidad de minería de datos y aprendizaje automático [12]. El conjunto de datos es accesible a través de OpenML con el identificador 1590 [16].

El dataset contiene 48,842 instancias y 14 atributos que describen características demográficas y socioeconómicas de individuos. La variable objetivo es binaria: si el ingreso anual es mayor a 50,000 USD o menor o igual a este umbral.

Los atributos del dataset se dividen en categóricos y continuos. En las Tablas 1 y 2 se resumen respectivamente.

Table 1: Descripción de variables numéricas del dataset Adult Census Income.

Atributo	Tipo	Rango	Descripción
age	Continuo	17 – 90 años	Edad del individuo
fnlwgt	Continuo	12,285 – 1,484,705	Peso final (factor de ponderación censal)
education.num	Continuo	1 – 16 años	Años de educación formal
capital.gain	Continuo	0 – 99,999 USD	Ganancia de capital
capital.loss	Continuo	0 – 4,356 USD	Pérdida de capital
hours.per.week	Continuo	1 – 99 horas	Horas trabajadas por semana

Table 2: Descripción de variables categóricas del dataset Adult Census Income.

Atributo	Tipo	Categorías	Descripción
workclass	Catagórico	8	Sector laboral (ej. Private, Self-emp-not-inc, Local-gov)
education	Catagórico	16	Nivel educativo (ej. HS-grad, Bachelors, Masters)
marital.status	Catagórico	7	Estado civil (ej. Married, Never-married, Divorced)
occupation	Catagórico	14	Ocupación específica (ej. Prof-specialty, Craft-repair)
relationship	Catagórico	6	Rol dentro del núcleo familiar (ej. Husband, Wife, Own-child)
race	Catagórico	5	Raza auto-reportada (ej. White, Black, Asian-Pac-Islander)
sex	Catagórico	2	Género (Male, Female)
native.country	Catagórico	41	País de nacimiento (ej. United-States, Mexico, Philippines)
income	Catagórico (Target)	2	Nivel de ingreso ($\leq 50K$ o $> 50K$)

Esta distribución evidencia un desbalance significativo entre las clases.

2.2 Análisis Exploratorio de Datos (EDA)

El Análisis Exploratorio de Datos (EDA) se realizó para comprender la estructura y las características principales del dataset, así como para identificar potenciales sesgos y relaciones entre las variables. A continuación, se presentan los hallazgos más relevantes.

Estructura General del Dataset El dataset está compuesto por **48,842 registros** y **15 variables**, de las cuales **6 son numéricas** y **9 son categóricas**. La variable objetivo es **income**, que clasifica a los individuos en dos categorías: ingresos menores o iguales a 50,000 USD ($\leq 50K$) y mayores a 50,000 USD ($> 50K$).

Distribución de la Variable Objetivo La variable objetivo `income` presenta un **desbalance significativo**. Como se muestra en la Tabla 3, aproximadamente el **76%** de los registros pertenecen a la clase `<=50K`, mientras que solo el **24%** corresponde a la clase `>50K`. Este desbalance es un factor crítico a considerar durante el entrenamiento de los modelos, ya que puede llevar a un sesgo hacia la clase mayoritaria y un rendimiento deficiente en la predicción de la clase minoritaria.

Table 3: Distribución de la variable objetivo `income`.

Clase	Descripción	Frecuencia	Porcentaje
Clase 0	<code><=50K</code>	24,720	76.1%
Clase 1	<code>>50K</code>	7,841	23.9%

Análisis de Correlación Se calculó la matriz de correlación de Pearson para identificar relaciones lineales entre las variables numéricas. Los resultados, mostrados en la Fig. 1, indican que las correlaciones son, en general, bajas. Sin embargo, se observan algunas relaciones positivas notables:

Estas correlaciones, aunque no son fuertes, sugieren que un mayor nivel educativo y una mayor cantidad de horas trabajadas podrían estar asociados con mejores niveles de ingreso, y que las ganancias de capital tienden a ser más altas en personas de mayor edad y con más horas de trabajo.




Fig. 1: Matriz de Correlacion.

Análisis de Variables Categóricas El estudio de las variables categóricas permitió identificar patrones relevantes en la composición demográfica y laboral de la población.

Table 4: Categorías predominantes en variables categóricas.

Variable	Categoría Predominante	Frecuencia	Porcentaje
workclass	Private	22,696	69.7%
education	HS-grad	10,501	32.2%
marital.status	Married-civ-spouse	14,976	46.0%
occupation	Prof-specialty	4,140	12.7%
relationship	Husband	13,193	40.5%
race	White	27,816	85.4%
sex	Male	21,790	66.9%
native.country	United-States	29,170	89.6%

Análisis de Valores Faltantes Inicialmente, el dataset no presentaba valores nulos explícitos. Sin embargo, se identificaron valores representados por el carácter ? en las variables categóricas, los cuales fueron tratados como valores faltantes.

Table 5: Valores faltantes identificados en variables categóricas.

Variable	Valores Faltantes (?)	Porcentaje
workclass	1,836	5.6%
occupation	1,843	5.7%
native.country	583	1.8%

Análisis de Valores Atípicos (Outliers) Se detectaron valores atípicos en las variables numéricas utilizando el método del rango intercuartílico (IQR). La Tabla 6 muestra la cantidad de outliers identificados en cada variable numérica.

Table 6: Valores atípicos detectados por variable numérica.

Variable	Número de valores atípicos	Observación
age	143	Se identificaron valores atípicos principalmente en edades extremas.
fnlwgt	992	Se observaron ponderaciones censales considerablemente alejadas del rango habitual.
education.num	1,198	Se detectaron valores extremos relacionados con los años de educación registrados.
capital.gain	2,712	Existe una alta concentración de valores iguales a cero y algunos picos en valores elevados.
capital.loss	1,519	Se presenta una alta concentración de valores iguales a cero y algunos valores extremadamente altos.
hours.per.week	9,008	Se identificó una gran cantidad de valores atípicos, especialmente en jornadas laborales muy bajas o muy elevadas.

2.3 Preprocesamiento de Datos

El preprocesamiento de los datos es un paso fundamental para garantizar la calidad y la eficacia de los modelos de machine learning. A continuación, se detallan las técnicas aplicadas al dataset *Adult Census Income*.

Manejo de Valores Faltantes Inicialmente, se realizó una inspección de valores nulos en el dataset. Aunque los métodos convencionales de detección de valores nulos no evidenciaron registros faltantes, el análisis detallado de las variables categóricas permitió identificar la presencia del símbolo ? en atributos como `workclass`, `occupation` y `native.country`, los cuales representan valores ausentes codificados de forma textual.

Table 7: Valores faltantes identificados antes del preprocesamiento.

Variable	Valores Faltantes	Porcentaje
workclass	1,836	5.6%
occupation	1,843	5.7%
native.country	583	1.8%

Para el manejo de estos valores faltantes, se implementaron las siguientes estrategias:

1. **Imputación por moda:** Los valores faltantes en las variables categóricas fueron reemplazados con la moda (valor más frecuente) de cada columna correspondiente [2]. Esta técnica es adecuada para variables categóricas, ya que preserva la distribución original de los datos.
2. **Eliminación de duplicados:** Se detectaron y eliminaron 24 registros duplicados dentro del conjunto de datos para evitar sesgos en el entrenamiento de los modelos.

Selección y Transformación de Variables Se realizó la eliminación de la variable `education` debido a su redundancia con la variable `education.num`, que ya contiene la información del nivel educativo en formato numérico. Esta decisión permite reducir la dimensionalidad del dataset sin pérdida de información relevante.

Codificación de Variables Categóricas Las variables categóricas se transformaron a formato numérico utilizando la técnica de **One-Hot Encoding**. Este método crea columnas binarias para cada categoría, representando la presencia (1) o ausencia (0) de cada categoría [1, 13].

$$\text{One-Hot Encoding: } X_{\text{categórica}} \rightarrow \{0, 1\}^k \quad (1)$$

Donde k es el número de categorías de la variable original.

Nota: Se aplicó la técnica de `drop_first=True` para evitar la multicolinealidad, eliminando una categoría de referencia en cada variable codificada.

Normalización de Variables Numéricas Para evitar sesgos por diferencias de escala entre las variables numéricas, se aplicó la técnica de **estandarización** utilizando `StandardScaler` de la librería `scikit-learn`. Esta técnica transforma los datos para que tengan media 0 y desviación estándar 1 [1].

$$z = \frac{x - \mu}{\sigma} \quad (2)$$

Donde μ es la media y σ es la desviación estándar de la característica.

Table 8: Estadísticos de las variables numéricas antes y después de la estandarización.

Variable	Media original	Desv. estándar original	Media escalada	Desv. estándar escalada
age	38.58	13.64	0.00	1.00
fnlwgt	189,778.37	105,549.98	0.00	1.00
education.num	10.08	2.57	0.00	1.00
capital.gain	1,077.65	7,385.29	0.00	1.00
capital.loss	87.30	402.96	0.00	1.00
hours.per.week	40.44	12.35	0.00	1.00

División de Datos Los datos fueron divididos en conjuntos de entrenamiento y prueba utilizando la técnica **Train-Test Split**. Se utilizó un 80% de los registros para entrenamiento y un 20% para prueba, empleando muestreo estratificado para mantener la proporción de clases en ambos conjuntos [1, 13].

Table 9: Distribución de los datos en los conjuntos de entrenamiento y prueba.

Conjunto	Registros	Porcentaje	Clase 0 ($\leq 50K$)	Clase 1 ($> 50K$)
Entrenamiento	26,029	80.0%	75.91%	24.09%
Prueba	6,508	20.0%	75.91%	24.09%

Parámetros utilizados:

- `test_size=0.20`: 20% de los datos para prueba
- `random_state=42`: Semilla para reproducibilidad
- `stratify=y`: Muestreo estratificado por la variable objetivo

Resumen del Dataset Final Después de aplicar todas las transformaciones, el dataset final quedó conformado de la siguiente manera:

Table 10: Resumen del dataset después del preprocesamiento.

Característica	Valor
Registros totales	32,537
Variables originales	15
Variables después de One-Hot Encoding	83
Variable objetivo	income (binaria)
Registros de entrenamiento	26,029
Registros de prueba	6,508

2.4 Algoritmos de Machine Learning

Para abordar el problema de clasificación binaria de ingresos, se implementaron y compararon cinco algoritmos de aprendizaje automático: Regresión Logística, Árbol de Decisión, Random Forest, Support Vector Machine (SVM) y Naive Bayes. A continuación, se detalla cada uno de ellos con su representación matemática y los parámetros utilizados en la implementación.

Regresión Logística La Regresión Logística es un modelo lineal utilizado para problemas de clasificación binaria. Modela la probabilidad de que una instancia pertenezca a una clase específica utilizando la función logística (sigmoide). Su representación matemática es:

$$P(y = 1|\mathbf{x}) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \dots + \beta_n x_n)}} \quad (3)$$

Donde $P(y = 1|\mathbf{x})$ es la probabilidad de que la salida sea 1 dado el vector de características $\mathbf{x}$, y β_i son los coeficientes del modelo que se aprenden durante el entrenamiento. La decisión de clasificación se toma comparando la probabilidad estimada con un umbral (generalmente 0.5).

Parámetros de implementación:

- `max_iter=5000`: Número máximo de iteraciones para la convergencia del algoritmo de optimización
- `random_state=42`: Semilla para reproducibilidad de resultados

Árbol de Decisión Los Árboles de Decisión son modelos no paramétricos que dividen recursivamente el espacio de características en regiones más homogéneas, utilizando una serie de reglas de decisión basadas en los valores de las características. La división se realiza seleccionando la característica que mejor separa los datos según una métrica de impureza.

La métrica utilizada en este trabajo fue la **impureza de Gini**:

$$Gini(t) = 1 - \sum_{k=1}^K p_{k|t}^2 \quad (4)$$

Donde $p_{k|t}$ es la proporción de muestras de clase k en el nodo t . El objetivo es minimizar la impureza en cada división para crear nodos hijos más puros. El proceso de construcción del árbol continúa hasta alcanzar un criterio de parada, como una profundidad máxima o un número mínimo de muestras por nodo.

Parámetros de implementación:

- `max_depth=10`: Profundidad máxima del árbol para evitar sobreajuste
- `random_state=42`: Semilla para reproducibilidad

Random Forest Random Forest es un método de ensemble learning que construye múltiples árboles de decisión durante el entrenamiento y combina sus predicciones mediante votación mayoritaria (para clasificación). La fortaleza de este método radica en dos principios de aleatorización:

1. **Bootstrap Sampling**: Cada árbol se entrena con una muestra aleatoria con reemplazo del conjunto de datos original.
2. **Random Feature Selection**: En cada división, solo se considera un subconjunto aleatorio de las características.

La predicción final del modelo se obtiene mediante votación mayoritaria:

$$\hat{y} = \text{moda}\{h_1(x), h_2(x), \dots, h_N(x)\} \quad (5)$$

Donde $h_i(x)$ es la predicción del i -ésimo árbol y N es el número total de árboles en el bosque.

Parámetros de implementación:

- `n_estimators=200`: Número de árboles en el bosque
- `random_state=42`: Semilla para reproducibilidad
- `n_jobs=-1`: Uso de todos los núcleos del procesador para paralelizar el entrenamiento

Support Vector Machine (SVM) Support Vector Machine es un clasificador que encuentra el hiperplano óptimo que maximiza el margen entre clases. Para datos linealmente separables, SVM resuelve el siguiente problema de optimización:

$$\min_{w,b} \frac{1}{2} \|w\|^2 \quad (6)$$

sujeto a:

$$y_i(w \cdot x_i + b) \geq 1 \quad (7)$$

Para datos no linealmente separables, SVM utiliza el **kernel trick** para mapear los datos a un espacio de características de mayor dimensión donde sean linealmente separables. En este trabajo se utilizó el **kernel RBF (Radial Basis Function)**:

$$K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2) \quad (8)$$

Donde γ es un parámetro que controla la influencia de una sola muestra de entrenamiento. El kernel RBF es particularmente útil cuando no se conoce la relación entre las características y la variable objetivo, ya que puede capturar relaciones no lineales complejas.

Parámetros de implementación:

- `random_state=42`: Semilla para reproducibilidad

Naive Bayes Naive Bayes es un clasificador probabilístico basado en el teorema de Bayes con el supuesto de independencia condicional entre las características dado la clase. Este supuesto, aunque fuerte, permite una implementación eficiente y un buen rendimiento en muchos problemas prácticos.

La probabilidad posterior de la clase C_k dado el vector de características $\mathbf{x}$ se calcula como:

$$P(C_k|\mathbf{x}) = \frac{P(C_k) \prod_{i=1}^n P(x_i|C_k)}{P(\mathbf{x})} \quad (9)$$

Para variables continuas, se asume que $P(x_i|C_k)$ sigue una distribución normal (Gaussiana):

$$P(x_i|C_k) = \frac{1}{\sqrt{2\pi\sigma_{ik}^2}} \exp\left(-\frac{(x_i - \mu_{ik})^2}{2\sigma_{ik}^2}\right) \quad (10)$$

Donde μ_{ik} y σ_{ik}^2 son la media y la varianza de la característica x_i para la clase C_k .

Parámetros de implementación:

- Se utilizó la implementación estándar de scikit-learn con los parámetros por defecto.

Table 11: Resumen de los algoritmos de machine learning implementados.

Modelo	Tipo	Características principales
Regresión logística	Lineal	Interpretable, rápida y adecuada para relaciones lineales.
Árbol de decisión	No lineal	Interpretable, captura interacciones entre variables, pero puede presentar sobreajuste.
Random Forest	Ensemble	Es robusto, reduce el sobreajuste y permite modelar relaciones no lineales.
SVM	Kernel	Captura relaciones complejas y su rendimiento depende de la selección de sus parámetros.
Naive Bayes	Probabilístico	Es rápido, supone independencia entre las variables y resulta adecuado para datos de alta dimensionalidad.

Resumen de Modelos Implementados En esta sección se presentan los resultados obtenidos al entrenar y evaluar los cinco modelos de clasificación sobre el conjunto de prueba (20% del dataset). La Tabla 12 resume el rendimiento de cada modelo en términos de Precisión (Accuracy), Precisión (Precision), Recall, F1-Score y Matthews Correlation Coefficient (MCC).

Table 12: Comparación de métricas de rendimiento de los modelos evaluados.

Modelo	Accuracy	Precision	Recall	F1-Score	MCC
Regresión Logística	0.8508	0.7345	0.5963	0.6582	0.5691
Árbol de Decisión	0.8485	0.7130	0.6212	0.6639	0.5690
Random Forest	0.8519	0.7316	0.6084	0.6643	0.5743
Support Vector Machine	0.8437	0.7353	0.5491	0.6287	0.5415

Comparativa de Modelos

2.5 Análisis por Modelo

Regresión Logística La Regresión Logística alcanzó una precisión global (Accuracy) del 85.08%, con un F1-Score de 0.6582 y un MCC de 0.5691. El modelo muestra un rendimiento equilibrado, con una precisión de 0.7345 y un recall de 0.5963 para la clase positiva (ingresos >50K).

Table 13: Informe de clasificación detallado para Regresión Logística.

Clase	Precision	Recall	F1-Score	Soporte
0 (<=50K)	0.88	0.93	0.90	4,940
1 (>50K)	0.73	0.60	0.66	1,568
Accuracy			0.85	6,508
Macro Avg	0.81	0.76	0.78	6,508
Weighted Avg	0.84	0.85	0.85	6,508

Análisis:

- Buen rendimiento en la clase mayoritaria (Recall: 0.93)
- Dificultad moderada para identificar la clase minoritaria (Recall: 0.60)
- Balance aceptable entre precisión y recall para la clase positiva (F1: 0.66)

Árbol de Decisión El Árbol de Decisión alcanzó una precisión global del 84.85%, con un F1-Score de 0.6639 y un MCC de 0.5690. Este modelo presenta el mejor recall (0.6212) entre todos los modelos evaluados para la clase positiva.

Table 14: Informe de clasificación detallado para Árbol de Decisión.

Clase	Precision	Recall	F1-Score	Soporte
0 (<=50K)	0.88	0.92	0.90	4,940
1 (>50K)	0.71	0.62	0.66	1,568
Accuracy			0.85	6,508
Macro Avg	0.80	0.77	0.78	6,508
Weighted Avg	0.84	0.85	0.84	6,508

Análisis:

- Mejor recall (0.62) para la clase positiva, indicando mayor sensibilidad
- Precisión ligeramente inferior (0.71) comparada con otros modelos
- F1-Score competitivo (0.66), similar a Random Forest

Random Forest Random Forest alcanzó la mejor precisión global (85.19%) y el mejor F1-Score (0.6643) y MCC (0.5743) entre todos los modelos evaluados.

Table 15: Informe de clasificación detallado para Random Forest.

Clase	Precision	Recall	F1-Score	Soporte
0 (<=50K)	0.88	0.93	0.90	4,940
1 (>50K)	0.73	0.61	0.66	1,568
Accuracy			0.85	6,508
Macro Avg	0.81	0.77	0.78	6,508
Weighted Avg	0.85	0.85	0.85	6,508

Análisis:

- Mejor rendimiento general con el F1-Score más alto (0.6643)
- MCC más alto (0.5743), indicando mejor correlación entre predicción y realidad
- Balance óptimo entre precisión (0.73) y recall (0.61) para la clase positiva
- Mayor robustez debido a la naturaleza de ensemble del modelo

Support Vector Machine (SVM) SVM alcanzó una precisión global del 84.37%, con un F1-Score de 0.6287 y un MCC de 0.5415. Este modelo presenta la precisión más alta (0.7353) pero el recall más bajo (0.5491) para la clase positiva.

Table 16: Informe de clasificación detallado para SVM.

Clase	Precision	Recall	F1-Score	Soporte
0 (<=50K)	0.87	0.94	0.90	4,940
1 (>50K)	0.74	0.55	0.63	1,568
Accuracy			0.84	6,508
Macro Avg	0.80	0.74	0.76	6,508
Weighted Avg	0.84	0.84	0.84	6,508

Análisis:

- Precisión más alta (0.74) para la clase positiva, indicando alta exactitud cuando predice ingresos >50K
- Recall más bajo (0.55), indicando que identifica menos de la mitad de los casos positivos reales
- F1-Score más bajo (0.63) debido al bajo recall
- Posible sobreajuste o necesidad de ajuste de hiperparámetros

2.6 Matrices de Confusión

Las matrices de confusión permiten visualizar el desempeño detallado de cada modelo.




Fig. 2: Matriz de confusión para Regresión Logística.




Fig. 3: Matriz de confusión para Arbol de Desicion.




Fig. 4: Matriz de confusión para Random Forest.




Fig. 5: Matriz de confusión para Support Vector Machine.

Árbol de Decisión

Random Forest

Support Vector Machine

2.7 Visualización de Resultados

La Figura 6 muestra la comparación visual de los modelos evaluados en términos de F1-Score y MCC.




Fig. 6: Comparación de modelos: F1-Score y MCC.

2.8 Interpretación de Resultados

El análisis de los resultados permite extraer las siguientes conclusiones:

1. **Mejor Modelo General:** El modelo **Random Forest** se destaca como el mejor en general, logrando el F1-Score más alto (0.6643) y el MCC más alto (0.5743). Su capacidad para manejar el desbalance de clases y capturar relaciones no lineales en los datos lo convierte en una opción robusta para este problema.
2. **Modelo de Referencia:** La **Regresión Logística** ofrece un buen punto de partida y un rendimiento consistente (F1: 0.6582), siendo una opción sencilla pero efectiva. Su interpretabilidad la hace valiosa para entender la influencia de las características.
3. **Mejor Recall:** El **Árbol de Decisión** presenta el mejor recall (0.6212) para la clase positiva, lo que indica que es el modelo más sensible para identificar individuos con ingresos >50K, aunque a costa de una precisión ligeramente menor.
4. **Desafíos del Desbalance de Clases:** La dificultad para predecir correctamente la clase minoritaria (ingresos >50K) es evidente en todos los modelos, como lo demuestran los valores de recall, que en ningún caso superan el 0.63. Esto subraya la importancia de aplicar técnicas de balanceo de clases o de optimizar los modelos para mejorar la sensibilidad hacia la clase minoritaria.

5. **Desempeño de SVM:** SVM, a pesar de su alto potencial en otros contextos, no fue el modelo más adecuado para este problema con la configuración utilizada. Su bajo recall (0.5491) sugiere que se beneficiaría de un ajuste de hiperparámetros más exhaustivo, especialmente en el parámetro de regularización C y el kernel, o de la aplicación de técnicas de balanceo de clases.

2.9 Resumen de Resultados

En resumen, para la tarea de clasificación de ingresos en el dataset Adult Census Income, **Random Forest emerge como la opción más equilibrada y efectiva**, ofreciendo el mejor compromiso entre precisión y recall, y demostrando ser más robusto para manejar las complejidades y desbalances de los datos.

Table 17: Resumen de resultados por modelo ordenado por F1-Score.

Modelo	Accuracy	Precision	Recall	F1-Score	MCC
Random Forest	0.8519	0.7316	0.6084	0.6643	0.5743
Árbol de Decisión	0.8485	0.7130	0.6212	0.6639	0.5690
Regresión Logística	0.8508	0.7345	0.5963	0.6582	0.5691
Support Vector Machine	0.8437	0.7353	0.5491	0.6287	0.5415

3 Discusión

Esta investigación aborda la problemática crítica del sesgo algorítmico en sistemas de clasificación de ingresos, destacando la importancia de considerar tanto la precisión predictiva como las implicaciones éticas de las decisiones automatizadas. Los resultados previstos sugieren que es posible alcanzar altos niveles de precisión mientras se mantienen estándares aceptables de equidad mediante intervenciones adecuadas.

Las limitaciones del estudio incluyen:

- **Validez externa limitada:** El dataset Adult Census Income, aunque ampliamente utilizado, fue recolectado en 1994 y puede no reflejar adecuadamente las condiciones socioeconómicas actuales [19].
- **Simplificación de atributos protegidos:** La dicotomización de género y raza puede no capturar adecuadamente la complejidad de estas identidades.
- **Métricas de equidad en debate:** Las métricas de equidad algorítmica son objeto de controversia y pueden no capturar todas las dimensiones de la injusticia.

4 Conclusión

Este trabajo presenta un análisis comprehensivo del dataset Adult Census Income, integrando técnicas avanzadas de aprendizaje automático con evaluaciones

de equidad algorítmica. Los resultados esperados validan la efectividad de modelos como Gradient Boosting y XGBoost para la clasificación de ingresos, al tiempo que demuestran la viabilidad de mitigar sesgos significativos mediante intervenciones como el re-pesaje y la optimización multiobjetivo.

Las contribuciones principales de esta investigación son:

1. Un marco metodológico integrado que combina rendimiento predictivo y evaluación de equidad.
2. Evidencia empírica sobre la efectividad de técnicas de mitigación de sesgos en el dominio de clasificación de ingresos.
3. Recomendaciones prácticas para el desarrollo de sistemas de IA responsables en contextos socioeconómicos.

Las líneas de investigación futura incluyen:

- Aplicación de modelos híbridos que combinen aprendizaje profundo con enfoques basados en árboles.
- Validación con datasets contemporáneos como Folktables para mejorar la generalización [19].
- Exploración de métricas de equidad individual complementarias a las métricas grupales.
- Desarrollo de sistemas de auditoría continua para monitorear y mantener estándares de equidad en producción.

References

1. Amanda, W., Voutama, A.: Income Classification Using Random Forest Algorithm: Case Study Adult Income Dataset. *Journal of Computer Science and Technology* **14**(1) (2025).
2. Aninze, A., Bhogal, J.: Artificial Intelligence Life Cycle: The Detection and Mitigation of Bias. Birmingham City University (2024).
3. Breiman, L.: Random Forests. *Machine Learning* **45**(1), 5-32 (2001).
4. Chakrabarty, N., Biswas, S.: A Statistical Approach to Adult Census Income Level Prediction. *IEEE Conference* (2018).
5. Chawla, N.V., Bowyer, K.W., Hall, L.O., Kegelmeyer, W.P.: SMOTE: Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research* **16**, 321-357 (2002).
6. Chen, T., Guestrin, C.: XGBoost: A Scalable Tree Boosting System. In: *Proceedings of the 22nd ACM SIGKDD* (2016).
7. Cortes, C., Vapnik, V.: Support-Vector Networks. *Machine Learning* **20**(3), 273-297 (1995).
8. Ding, F., Hardt, M., Miller, J., Schmidt, L.: Retiring Adult: New Datasets for Fair Machine Learning. In: *Advances in Neural Information Processing Systems*, vol. 34, pp. 6478-6490 (2021).
9. Friedman, J.H.: Greedy Function Approximation: A Gradient Boosting Machine. *Annals of Statistics* **29**(5), 1189-1232 (2001).
10. Girhepuje, S.: Identifying and Examining Machine Learning Biases on Adult Dataset. *Indian Institute of Technology Madras* (2021).

11. Kohavi, R.: Scaling Up the Accuracy of Naive-Bayes Classifiers: A Decision-Tree Hybrid. In: Proceedings of the Second International Conference on Knowledge Discovery and Data Mining, pp. 202-207 (1996).
12. Kohavi, R., Becker, B.: Adult Data Set. UCI Machine Learning Repository (1996).
13. Kokate, A., Nemade, B., Badhe, N., Mali, D., Gaikwad, K., Ansari, N.: Bias and Its Consequences: A Study of Machine Learning Models on Biased Data. *International Journal of Scientific Research in Computer Science, Engineering and Information Technology* **10**(6), 290-301 (2024).
14. Lewis, D.D.: Naive (Bayes) at Forty: The Independence Assumption in Information Retrieval. In: Proceedings of the 10th European Conference on Machine Learning, pp. 4-15 (1998).
15. Nagpal, R., Shahsavarifar, R.R., Goyal, V., Gupta, A.: Optimizing fairness and accuracy: a Pareto optimal approach for decision-making. *AI and Ethics* **5**, 1743-1756 (2025).
16. Vanschoren, J., van Rijn, J.N., Bischl, B., Torgo, L.: OpenML: Networked Science in Machine Learning. *ACM SIGKDD Explorations Newsletter* **15**(2), 49-60 (2014), <https://archive.ics.uci.edu/dataset/2/adult>.
17. Chakrabarty, N., Biswas, S.: A statistical approach to adult census income level prediction. Technical Report, Department of Computer Science and Engineering, Jalpaiguri Government Engineering College (2018).
18. Kohavi, R.: Scaling up the accuracy of Naive-Bayes classifiers: a decision-tree hybrid. In: Proceedings of the Second International Conference on Knowledge Discovery and Data Mining (KDD'96), pp. 202-207. AAAI Press (1996).
19. Ding, F., Hardt, M., Miller, J., Schmidt, L.: Retiring Adult: new datasets for fair machine learning. In: *Advances in Neural Information Processing Systems* (NeurIPS), vol. 34, pp. 6478-6490. Curran Associates, Inc. (2021).
20. Nagpal, R., Shahsavarifar, R.R., Goyal, V., Gupta, A.: Optimizing fairness and accuracy: a Pareto optimal approach for decision-making. *AI and Ethics* **5**, 1743-1756 (2025). <https://doi.org/10.1007/s43681-024-00508-4>
21. Aninze, A., Bhogal, J.: Artificial intelligence life cycle: the detection and mitigation of bias. In: Proceedings of the International Conference on AI Ethics. Birmingham City University, UK (2024).
22. Girhepuje, S.: Identifying and examining machine learning biases on Adult dataset. M.Tech. Thesis, Indian Institute of Technology Madras (2021).
23. Bendoukha, A.-A., Kaaniche, N., Boudguiga, A., Sirdey, R.: FairCognizer: a model for accurate predictions with inherent fairness evaluation. In: *ECAI 2024: 27th European Conference on Artificial Intelligence, Frontiers in Artificial Intelligence and Applications*. IOS Press (2024).